



Università degli Studi di Bari

DIPARTIMENTO DI INFORMATICA
Corso di Laurea Magistrale in Informatica

PROGETTO DI INTELLIGENZA ARTIFICIALE

CONFRONTO TRA DUE ALGORITMI DI APPRENDIMENTO

Esaminando:

Giuseppe Rizzi

Matricola 591275

Docenti:

Prof. Floriana Esposito

Prof. Nicola Di Mauro

Indice

1	Introduzione	2
2	Descrizione dei dati	3
2.1	German Credit dataset	3
2.2	Image Segmentation dataset	4
2.3	Vehicle Silhouettes dataset	5
2.4	Wisconsin Breast Cancer dataset	6
3	REPTree	8
3.1	Information Gain	8
3.2	Reduced Error Pruning	9
4	RIPPER	11
4.1	Incremental Reduced Error Pruning	12
4.2	Miglioramenti ad IREP	14
5	Esecuzione	17
5.1	Risultati su German Credit	17
5.2	Risultati su Image Segmentation	22
5.3	Risultati su Vehicle Silhouettes	27
5.4	Risultati su Wisconsin Breast Cancer	32

Capitolo 1: Introduzione

Il seguente lavoro si propone di confrontare due algoritmi di apprendimento supervisionato, *REPTree* e *RIPPER*: il primo sfrutta la metodologia di costruzione di alberi di decisione, il secondo quello di costruzione di regole.

Verranno testati su quattro dataset messi a disposizione dall'*UCI Machine Learning Repository*¹, procedendo con la presentazione dei risultati e dei modelli di predizione ottenuti.

Il software utilizzato è *Weka*², una suite di algoritmi di *machine learning*, fortemente utilizzato sia in ambito accademico che industriale.

¹<https://archive.ics.uci.edu/ml/datasets.html>

²<http://www.cs.waikato.ac.nz/ml/weka/>

Capitolo 2: Descrizione dei dati

Di seguito vengono descritti i 4 dataset utilizzati nella sperimentazione

2.1 German Credit dataset

Il dataset contiene informazioni in ambito finanziario su clienti ritenuti a rischio o meno.

- Numero di istanze: 1000
- Numero di attributi: 21
- Attributo target: **class**
- Valori target: {good, bad}

Attributo	Tipo
checking_status	nominal
duration	numeric
credit_history	nominal
purpose	nominal
credit_amount	numeric
savings_status	nominal
employment	nominal
installment_commitment	numeric
personal_status	nominal
other_parties	nominal
residence_since	numeric
property_magnitude	nominal
age	numeric
other_payment_plans	nominal
housing	nominal
existing_credits	numeric
job	nominal
num_dependents	numeric
own_telephone	nominal
foreign_worker	nominal
class	nominal

2.2 Image Segmentation dataset

Il dataset contiene informazioni di sette immagini all'aperto che sono state segmentate a mano. Ogni istanza rappresenta una regione 3x3.

- Numero di istanze: 2310
- Numero di attributi: 20
- Attributo target: **class**
- Valori target: {brickface, sky, foliage, cement, window, path, grass}

Attributo	Tipo
region-centroid-col	numeric
region-centroid-row	numeric
region-pixel-count	numeric
short-line-density-5	numeric
short-line-density-2	numeric
vedge-mean	numeric
vegde-sd	numeric
hedge-mean	numeric
hedge-sd	numeric
intensity-mean	numeric
rawred-mean	numeric
rawblue-mean	numeric
rawgreen-mean	numeric
exred-mean	numeric
exblue-mean	numeric
exgreen-mean	numeric
value-mean	numeric
saturation-mean	numeric
hue-mean	numeric
class	nominal

2.3 Vehicle Silhouettes dataset

Il dataset contiene informazioni per discriminare le silhouette di diversi veicoli tra automobili, van e bus.

- Numero di istanze: 846
- Numero di attributi: 19
- Attributo target: **Class**
- Valori target: {opel, saab, bus, van}

Attributo	Tipo.
COMPACTNESS	numeric
CIRCULARITY	numeric
DISTANCE CIRCULARITY	numeric
RADIUS RATIO	numeric
PR.AXIS ASPECT RATIO	numeric
MAX.LENGTH ASPECT RATIO	numeric
SCATTER RATIO	numeric
ELONGATEDNESS	numeric
PR.AXIS RECTANGULARITY	numeric
MAX.LENGTH RECTANGULARITY	numeric
SCALED VARIANCE_MAJOR	numeric
SCALED VARIANCE_MINOR	numeric
SCALED RADIUS OF GYRATION	numeric
SKEWNESS ABOUT_MAJOR	numeric
SKEWNESS ABOUT_MINOR	numeric
KURTOSIS ABOUT_MAJOR	numeric
KURTOSIS ABOUT_MINOR	numeric
HOLLOWS RATIO	numeric
Class	nominal

2.4 Wisconsin Breast Cancer dataset

Il dataset contiene informazioni riguardo a vari casi di tumore al seno, che permettono di stabilire se esso è benigno o maligno.

- Numero di istanze: 699
- Numero di attributi: 10
- Attributo target: **Class**
- Valori target: {benign, malignant}

Attributo	Tipo
Clump_Thickness	numeric
Cell_Size_Uniformity	numeric
Cell_Shape_Uniformity	numeric
Marginal_Adhesion	numeric
Single_Epi_Cell_Size	numeric
Bare_Nuclei	numeric
Bland_Chromatin	numeric
Normal_Nucleoli	numeric
Mitoses	numeric
Class	nominal

Capitolo 3: REPTree

Come primo algoritmo si è scelto di usare **REPTree**, che costruisce alberi di decisione usando l'*information gain* per i valori nominali e la varianza per i valori numerici[16].

Visto che sono stati presi in considerazione dataset con attributi di classe nominali per un task di classificazione e non di regressione, verrà discusso il criterio dell'*information gain*, analogo all'algoritmo *C4.5*[9].

3.1 Information Gain

Per selezionare l'attributo che meglio classifica i dati D ed in particolare, su quale dei suoi valori occorre fare uno *split*, può convenire usare l'*entropia*[13], ossia l'incertezza contenuta nei dati, che è calcolata come:

$$E(D) = - \sum_i p_i \log_2 p_i$$

cioè la media dei logaritmi delle probabilità di ciascun oggetto i pesato per la probabilità stessa. Nel contesto di classificazione, gli oggetti sono gli esempi nel dataset di cui viene calcolata la probabilità che essi appartengano o meno ad una delle classi presenti nell'attributo target. Più è probabile che un esempio appartenga ad una certa classe, più la sua influenza nel calcolo della media sarà mitigata dal logaritmo della sua stessa probabilità.

È possibile calcolare l'entropia anche per sottoinsiemi del dataset, in particolare quegli esempi D_v che presentano lo stesso valore v di un certo attributo a , poi sommare tutte le entropie relative a tutti i valori V dell'attributo per ottenere l'entropia dei dati dopo aver preso in considerazione l'attributo a . Ogni entropia viene pesata per il numero di esempi che presentano quel valore diviso per il totale di esempi esistenti nel dataset:

$$E(D|a) = \sum_{v \in V} \frac{|D_v|}{|D|} \cdot E(D_v)$$

Da queste formule si ricava l'information gain, cioè la riduzione di incertezza totale prendendo in considerazione un attributo a :

$$IG = E(D) - E(D|a)$$

Come radice verrà utilizzato l'attributo che massimizza l'information gain, come archi i valori dell'attributo e si ripete la procedura per i nodi figli fino a generare le foglie.

3.2 Reduced Error Pruning

Per evitare l'*overfitting*, ossia un sovra-adattamento del modello ai dati di training che compromette la bontà delle sue predizioni su nuovi esempi, può essere ragionevole semplificare il modello, rischiando di commettere qualche errore ma garantendoci una migliore copertura per dati non visti.

Questa semplificazione viene chiamata *pruning* (potatura), in cui, una volta costruito il modello utilizzando i dati del *growing set*, esso viene testato su una parte dei dati, accantonati e non adoperati per la predizione, che fanno parte del *pruning set*.

Una tecnica di potatura è REP (**R**educed **E**rror **P**runing)[8] che utilizza un pruning set per stimare l'accuratezza dei nodi intermedi e confrontarla con quella dei suoi sottoalberi.

Viene calcolato il guadagno dall'eventuale potatura sottraendo il numero di errori (esempi classificati scorrettamente) al sottoalbero T al numero di errori al nodo radice v del sottoalbero:

$$Gain_{REP} = \varepsilon_T - \varepsilon_v$$

L'albero è potato se il guadagno è positivo quando vengono commessi più errori nell'intero sottoalbero, e non al nodo. C'è un'altra condizione da rispettare per procedere alla potatura: può avvenire solo se il sottoalbero T non ha un sottoalbero che ha un tasso d'errore minore di T stesso (*bottom-up restriction*).

L'algoritmo di REP è il seguente:

- Si parte dall'albero completo e lo si visita in post-ordine.
- Per ogni nodo intermedio v
 - Calcolo l'accuratezza sul pruning set dell'albero completo.
 - Calcolo l'accuratezza sul pruning set rispetto a v e al suo sottoalbero T .

- Se l'accuratezza aumenta, pota. In caso di uguaglianza pota per semplificare (rasoio di Occam).

Inoltre è dimostrato che, tra tutti i possibili sottoalberi potati che è possibile generare, REP trova il sottoalbero più piccolo e più accurato rispetto al pruning set[4].

Capitolo 4: RIPPER

Come secondo algoritmo si è scelto di usare **RIPPER**[3], in particolare nella versione implementata da Weka, **JRip**[17].

RIPPER (**R**epeated **I**ncremental **P**runing to **P**roduce **E**rror **R**eduction) è un algoritmo di induzione di regole proposto da William W. Cohen nel 1995. Esso si è dimostrato competitivo con C4.5Rules rispetto ai tassi di errore, scala in maniera lineare con il numero di esempi di training e può elaborare in maniera efficiente dataset rumorosi che contengono centinaia di migliaia di esempi. RIPPER si basa su IREP (**I**ncremental **R**educed **E**rror **P**runing))[5], di cui si discuterà nei prossimi paragrafi.

Molte delle tecniche usate nei moderni sistemi di apprendimento di regole sono state adattate dall'apprendimento degli alberi di decisione. La maggior parte dei sistemi di apprendimento di alberi di decisione usa una strategia di apprendimento *overfit-and-simplify* (sovradata-e-semplifica) per gestire dati rumorosi: viene generata un'ipotesi prima facendo crescere un albero complesso che "overfitta" i dati, e poi si semplifica o pota tale albero (un'operazione di *pruning*). Una tecnica di pruning efficace è *reduced error pruning* (*REP*), discussa in 3.2. Essa può essere facilmente adattata ai sistemi di apprendimento di regole[6][1].

In REP per le regole, il training set viene diviso in *growing set* e *pruning set*. All'inizio, viene creato un *rule set* di partenza che overfitta il growing set, usando qualche metodo euristico. Questo rule set spropositato viene poi semplificato ripetutamente applicando qualche operatore di pruning. Ad ogni fase di semplificazione, l'operatore di pruning scelto è quello che produce la più grande riduzione di errore sul pruning set. La semplificazione finisce quando il tasso di errore non si riduce ulteriormente applicando gli operatori di pruning.

REP per le regole di solito migliora davvero la performance di generalizzazione sui dati rumorosi[6][1][14][5]; tuttavia è computazionalmente costoso per grandi dataset[2].

In risposta all'inefficienza di REP, Fürnkranz e Widmer [1994] proposero un algoritmo di apprendimento chiamato *incremental reduced error pruning*

(IREP)[5].

4.1 Incremental Reduced Error Pruning

L'idea di usare un pruning set separato per la potatura è REP. La variante che pota una regola subito dopo averla "fatta crescere" si chiama *incremental reduced error pruning* (IREP)[15]. Quest'ultima integra saldamente REP con un algoritmo di apprendimento di regole *separate-and-conquer*. L'algoritmo 1 ne presenta una versione a due classi. Come ogni algoritmo *separate-and-conquer* standard, IREP costruisce un ruleset in maniera *greedy*, una regola alla volta. Dopo averne trovata una, tutti gli esempi coperti da quella regola (sia positivi che negativi) sono cancellati. Questo processo si ripete finché non ci sono più esempi positivi, o finché la regola trovata da IREP non presenta un grande tasso di errore, cosa inaccettabile.

Per costruire una regola, IREP usa la seguente strategia. Prima, gli esempi non coperti sono partizionati a caso in due sottoinsiemi, un growing e un pruning set. Nell'implementazione di Cohen, il growing set contiene 2/3 degli esempi.

Poi, una regola viene "fatta crescere". L'implementazione di Cohen di *GrowRule* è una versione proposizionale di FOIL (First Order Inductive Learner), dove i letterali non si servono di predicati ma di uguaglianze (per valori discreti) e confronti numerici (per valori continui)[12]. Esso inizia con una congiunzione vuota di condizioni (la regola vuota) e considera di aggiungere a questa qualsiasi condizione nella forma $A_d = v$, $A_c \leq \theta$ oppure $A_c \geq \theta$ dove A_d è un attributo discreto e v è un valore che può assumere, mentre A_c è un attributo continuo e θ è un valore soglia. *GrowRule* aggiunge ripetutamente la condizione che massimizza un'euristica di *information gain*, nello specifico quella di FOIL, finché la regola non copre più esempi negativi nel growing set.

Siano R_0 e R_1 due regole, la seconda ottenuta dall'aggiunta di una condizione nel corpo della prima. L'information gain viene così calcolato:

$$Gain_{IREP}(R_0, R_1) = t \cdot \left(\log \frac{p_1}{p_1 + n_1} - \log \frac{p_0}{p_0 + n_0} \right)$$

dove t riguarda gli esempi positivi coperti da R_0 che soddisfano anche R_1 dopo aver aggiunto una condizione, p_0 (rispettivamente p_1) sono gli esempi positivi coperti da R_0 (rispettivamente R_1) e n_0 (rispettivamente n_1) sono gli esempi negativi coperti da R_0 (rispettivamente R_1).

L'idea alla base è che l'informazione totale che si guadagna è dato dal numero di tuple che soddisfano la nuova condizione moltiplicato l'informazione guadagnata in merito a ciascuna[7].

Dopo aver espanso una regola, essa viene immediatamente potata. Per prunarla, l'implementazione di Cohen cancella qualsiasi sequenza finale di condizioni dalla regola e sceglie l'eliminazione che massimizza la funzione

$$v(Rule, PrunePos, PruneNeg) \equiv \frac{p + (N - n)}{P + N} \quad (4.1)$$

dove P (rispettivamente N) è il numero totale di esempi in $PrunePos$ ($PruneNeg$) e p (n) è il numero di esempi in $PrunePos$ ($PruneNeg$) coperti da $Rule$. Questo processo è ripetuto finché nessun'altra cancellazione migliora il valore di v .

L'algoritmo IREP descritto sopra è per i problemi di apprendimento a due classi. L'implementazione di Cohen gestisce classi multiple, come spiegato di seguito:

1. Le classi vengono ordinate secondo la prevalenza, cioè l'ordine è C_1, \dots, C_k dove C_1 è la classe di minoranza e C_k è la classe di maggioranza.
2. Viene trovata una regola che separi C_1 dal resto delle classi; questo viene fatto con una singola chiamata ad IREP dove $PosData$ contiene gli esempi di classe C_1 e $NegData$ contiene gli esempi di classi C_2, C_3, \dots, C_k .
3. Tutte le istanze coperte dal ruleset appena addestrato sono rimosse dal dataset e IREP si appresta a separare C_2 dalle classi C_3, \dots, C_k .
4. Si ripete finché rimane la sola classe C_k . Quest'ultima verrà usata come classe di default.

L'implementazione di Cohen differisce da quella di Fürnkranz e Widmer sotto molti aspetti. Quando le regole vengono potate, la nuova implementazione permette di cancellare qualsiasi sequenza finale di condizioni, mentre l'implementazione di Fürnkranz e Widmer permette solo la cancellazione di una singola condizione finale. L'algoritmo rivisitato permette anche di fermare l'aggiunta di regole al ruleset quando la regola appresa ha un tasso di errore superiore al 50%, mentre quello di Fürnkranz e Widmer la ferma quando l'accuratezza della regola è minore dell'accuratezza della regola vuota.

Algoritmo 1 IREP(Pos, Neg)

```
1:  $Ruleset \leftarrow \emptyset$ 
2: while  $Pos \neq \emptyset$  do
3:   dividi  $(Pos, Neg)$  in  $(GrowPos, GrowNeg)$  e  $(PrunePos, PruneNeg)$ 
4:    $Rule \leftarrow GrowRule(GrowPos, GrowNeg)$ 
5:    $Rule \leftarrow PruneRule(Rule, PrunePos, PruneNeg)$ 
6:   if il tasso di errore su  $(PrunePos, PruneNeg) > 50\%$  then
7:     return  $Ruleset$ 
8:   else
9:     aggiungi  $Rule$  a  $Ruleset$ 
10:    rimuovi gli esempi coperti da  $Rule$  da  $(Pos, Neg)$ 
11: return  $Ruleset$ 
```

4.2 Miglioramenti ad IREP

Sono state implementate tre modifiche ad IREP: una metrica alternativa per determinare il valore delle regole nella fase di potatura; una nuova euristica per decidere quando fermare l'aggiunta di regole al ruleset; un successivo passaggio di "ottimizzazione" del ruleset per tentare di avvicinarsi di più al REP convenzionale (cioè, non incrementale).

Metrica per il valore delle regole

Il fallimento occasionale di IREP a convergere al crescere del numero degli esempi può essere facilmente fatto risalire alla metrica usata per guidare la potatura (ossia la (4.1)). Le scelte intraprese nella definizione di tale metrica non sono intuitive; per esempio (assumendo che P e N siano fissati) la metrica preferisce una regola R_1 che copre $p_1 = 2000$ esempi positivi e $n_1 = 1000$ esempi negativi rispetto ad una regola R_2 che copre $p_2 = 1000$ esempi positivi e $n_2 = 1$ esempio negativo; si noti comunque che R_2 è altamente predittiva, al contrario di R_1 . Quindi si è deciso di sostituire la metrica di IREP con

$$v^*(Rule, PrunePos, PruneNeg) \equiv \frac{p - n}{p + n}$$

che sembra avere un comportamento più intuitivo e soddisfacente.

Condizione di stop

L'implementazione di IREP di Cohen si ferma in maniera greedy aggiungendo regole al ruleset quando l'ultima regola costruita ha un tasso d'errore

maggiore del 50% sui dati di pruning. Questa euristica, spesso, si ferma troppo presto con campioni di dimensioni moderate; questo è vero soprattutto quando si apprende un concetto con regole a bassa copertura (pochi esempi coperti).

La soluzione a questo problema è la seguente. Dopo l'aggiunta di ogni regola, viene calcolata la *description-length* totale del ruleset e degli esempi. La nuova versione di IREP ferma l'aggiunta di regole quando questa *description-length* è maggiore di d bit rispetto alla più piccola *description-length* ottenuta sinora, o quando non ci sono più esempi positivi. Nell'implementazione si è usato $d = 64$. Il ruleset viene poi semplificato esaminando ogni regola a turno (cominciando dall'ultima) e cancellando regole così da ridurre la *description-length* totale.

Il principio *MDL* (Minimum Description Length) può essere meglio espresso immaginando un modello di comunicazione in cui un mittente trasmette ad un ricevente una descrizione che consiste in una teoria T e i dati D da cui essa è derivata[11].

Il metodo usato per la codifica è lo stesso usato in *C4.5rules*[10]. Esso parte da un *bias* in cui il numero di falsi positivi e falsi negativi sia lo stesso e si procede come segue: i messaggi da inviare si presentano con probabilità p_j , e servono $-\log(p_j)$ bit (in base 2) per costruirli: più un messaggio è frequente, meno bit saranno necessari per rappresentarlo. Si inviano i dati codificati, poi anziché inviare i messaggi di errore per tutti i dati, il mittente prima trasmette gli errori e nei C casi coperti dalla teoria e poi negli U casi non coperti. Sotto l'assunzione che i falsi positivi fp e i falsi negativi fn siano bilanciati, la probabilità di errore nei casi coperti è $e/2C$ e questa probabilità è usata per codificare i messaggi di errore per i casi coperti. Una volta che i falsi positivi sono stati identificati, il destinatario può calcolare il vero numero dei falsi negativi come $e - fp$, quindi la probabilità di errore per i casi non coperti è fn/U . Il costo totale quindi diventa:

$$\begin{aligned}
& \log(|D| + 1) \\
& + fp \times (-\log(\frac{e}{2C})) \\
& + (C - fp) \times (-\log(1 - \frac{e}{2C})) \\
& + fn \times (-\log(\frac{fn}{U})) \\
& + (U - fn) \times (-\log(1 - \frac{fn}{U}))
\end{aligned}$$

Ottimizzazione delle regole

L'approccio ripetuto *grow-and-simplify* usato in IREP può produrre risultati abbastanza differenti dal REP convenzionale (non incrementale). Un modo per migliorarlo è elaborare a posteriori le regole prodotte da IREP così da avvicinarsi di più all'effetto del REP convenzionale. Per esempio, si potrebbe ri-potare ogni regola al fine di minimizzare l'errore del ruleset completo.

Il metodo sviluppato per ottimizzare un ruleset R_1, R_2, \dots, R_k consiste nel costruire due regole alternative per ogni R_i . La *sostituta* di R_i viene generata espandendo e poi potando R_i . La *revisione* di R_i viene generata in maniera analoga, tranne per il fatto che la revisione è espansa in modo greedy aggiungendo condizioni a R_i , piuttosto che alla regola vuota. Infine si sceglie tra le tre regole quale includere nella teoria. Questa decisione viene presa in base all'euristica MDL. L'implementazione di questo metodo in IREP avviene in questo modo:

1. Viene usato IREP per ottenere un ruleset iniziale.
2. Esso viene ottimizzato, come descritto sopra.
3. Vengono aggiunte le regole in modo tale da coprire gli esempi positivi rimanenti.

L'ottimizzazione può essere ripetuta più volte elaborando il ruleset ottenuto dalla passata precedente dell'algoritmo.

IREP, con l'aggiunta del passo di post-ottimizzazione, forma un nuovo algoritmo che è stato chiamato **RIPPER** (**R**epeated **I**ncremental **P**runing to **P**roduce **E**rror **R**eduction).

L'implementazione in Weka di RIPPER si chiama JRip.

Capitolo 5: Esecuzione

Qui vengono confrontati i due algoritmi REPTree e RIPPER/JRip. Entrambi hanno sfruttato una *10-fold cross validation*.

5.1 Risultati su German Credit

L'esecuzione ha coinvolto 900 istanze di training e 100 istanze di testing.

Esecuzione REPTree

=== Run information ===

Scheme:weka.classifiers.trees.REPTree -M 2 -V 0.001 -N 3 -S 1 -L -1

Relation: german_credit

Instances: 1000

Attributes: 21

checking_status

duration

credit_history

purpose

credit_amount

savings_status

employment

installment_commitment

personal_status

other_parties

residence_since

property_magnitude

age

other_payment_plans

housing

existing_credits

job

num_dependents

own_telephone

foreign_worker

```

class
Test mode:10-fold cross-validation

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      718           71.8   %
Incorrectly Classified Instances    282           28.2   %
Kappa statistic                    0.2702
Mean absolute error                 0.3417
Root mean squared error            0.4424
Relative absolute error            81.3157 %
Root relative squared error        96.532  %
Total Number of Instances         1000

=== Detailed Accuracy By Class ===

                TP Rate   FP Rate   Precision   Recall   F-Measure   ROC Area   Class
                0.859     0.61      0.767      0.859     0.81        0.72      good
                0.39     0.141    0.542      0.39     0.453       0.72      bad
Weighted Avg.   0.718     0.469    0.699      0.718     0.703       0.72

=== Confusion Matrix ===

  a    b  <-- classified as
601  99 |   a = good
183 117 |   b = bad

```

Key Fold Measures	1	2	3	4	5	6	7	8	9	10
Number correct	71	74	73	71	66	72	74	66	75	76
Number incorrect	29	26	27	29	34	28	26	34	25	24
Number unclassified	0	0	0	0	0	0	0	0	0	0
Percent correct	71	74	73	71	66	72	74	66	75	76
Percent incorrect	29	26	27	29	34	28	26	34	25	24
Percent unclassified	0	0	0	0	0	0	0	0	0	0
True positive rate	0.814286	0.928571	0.857143	0.842857	0.785714	0.928571	0.885714	0.742857	0.942857	0.857143
Num true positives	57	65	60	59	55	65	62	52	66	60
False positive rate	0.533333	0.7	0.566667	0.6	0.633333	0.766667	0.6	0.533333	0.7	0.466667
Num false positives	16	21	17	18	19	23	18	16	21	14
True negative rate	0.466667	0.3	0.433333	0.4	0.366667	0.233333	0.4	0.466667	0.3	0.533333
Num true negatives	14	9	13	12	11	7	12	14	9	16
False negative rate	0.185714	0.071429	0.142857	0.157143	0.214286	0.071429	0.114286	0.257143	0.057143	0.142857
Num false negatives	13	5	10	11	15	5	8	18	4	10
Precision	0.780822	0.755814	0.779221	0.766234	0.743243	0.738636	0.775	0.764706	0.758621	0.810811
Recall	0.814286	0.928571	0.857143	0.842857	0.785714	0.928571	0.885714	0.742857	0.942857	0.857143
F-measure	0.797203	0.833333	0.816327	0.802721	0.763889	0.822785	0.826667	0.753623	0.840764	0.833333

Tabella 5.1: Risultati della 10-fold CV per REPTree




Figura 5.1: Modello di REPTree

Esecuzione JRip

=== Run information ===

Scheme:weka.classifiers.rules.JRip -F 3 -N 2.0 -O 2 -S 1

Relation: german_credit

Instances: 1000

Attributes: 21

checking_status
duration
credit_history
purpose
credit_amount
savings_status
employment
installment_commitment
personal_status
other_parties
residence_since
property_magnitude
age
other_payment_plans
housing
existing_credits
job
num_dependents
own_telephone
foreign_worker
class

Test mode:10-fold cross-validation

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances	717	71.7	%
Incorrectly Classified Instances	283	28.3	%
Kappa statistic	0.2513		
Mean absolute error	0.3781		
Root mean squared error	0.4472		
Relative absolute error	89.9974	%	
Root relative squared error	97.5906	%	
Total Number of Instances	1000		

=== Detailed Accuracy By Class ===

TP Rate	FP Rate	Precision	Recall	F-Measure	ROC Area	Class
0.873	0.647	0.759	0.873	0.812	0.593	good
0.353	0.127	0.544	0.353	0.428	0.593	bad

Weighted Avg. 0.717 0.491 0.694 0.717 0.697 0.593

=== Confusion Matrix ===

```

      a    b    <-- classified as
611  89 |    a = good
194 106 |    b = bad

```

<i>Measures \ Key Fold</i>	1	2	3	4	5	6	7	8	9	10
Number correct	71	74	73	71	66	72	74	66	75	76
Number incorrect	29	26	27	29	34	28	26	34	25	24
Number unclassified	0	0	0	0	0	0	0	0	0	0
Percent correct	71	74	73	71	66	72	74	66	75	76
Percent incorrect	29	26	27	29	34	28	26	34	25	24
Percent unclassified	0	0	0	0	0	0	0	0	0	0
True positive rate	0.814286	0.928571	0.857143	0.842857	0.785714	0.928571	0.885714	0.742857	0.942857	0.857143
Num true positives	57	65	60	59	55	65	62	52	66	60
False positive rate	0.533333	0.7	0.566667	0.6	0.633333	0.766667	0.6	0.533333	0.7	0.466667
Num false positives	16	21	17	18	19	23	18	16	21	14
True negative rate	0.466667	0.3	0.433333	0.4	0.366667	0.233333	0.4	0.466667	0.3	0.533333
Num true negatives	14	9	13	12	11	7	12	14	9	16
False negative rate	0.185714	0.071429	0.142857	0.157143	0.214286	0.071429	0.114286	0.257143	0.057143	0.142857
Num false negatives	13	5	10	11	15	5	8	18	4	10
Precision	0.780822	0.755814	0.779221	0.766234	0.743243	0.738636	0.775	0.764706	0.758621	0.810811
Recall	0.814286	0.928571	0.857143	0.842857	0.785714	0.928571	0.885714	0.742857	0.942857	0.857143
F-measure	0.797203	0.833333	0.816327	0.802721	0.763889	0.822785	0.826667	0.753623	0.840764	0.833333

Tabella 5.2: Risultati della 10-fold CV per JRip

Regole:

1. (checking_status = "<0") **AND** (job = skilled) \Rightarrow class=bad (172.0/76.0)
2. (checking_status = "0<=X<20") **AND** (duration >= 24) **AND** (savings_status = "<100") \Rightarrow class=bad (61.0/19.0)
3. [Empty Rule] \Rightarrow class=good (767.0/162.0)

5.2 Risultati su Image Segmentation

L'esecuzione ha coinvolto 2079 istanze di training e 231 istanze di testing.

Esecuzione REPTree									
=== Run information ===									
Scheme:	weka.classifiers.trees.REPTree -M 2 -V 0.001 -N 3 -S 1 -L -1 -I 0.0								
Relation:	segment								
Instances:	2310								
Attributes:	20								
	region-centroid-col								
	region-centroid-row								
	region-pixel-count								
	short-line-density-5								
	short-line-density-2								
	vedge-mean								
	vedge-sd								
	hedge-mean								
	hedge-sd								
	intensity-mean								
	rawred-mean								
	rawblue-mean								
	rawgreen-mean								
	exred-mean								
	exblue-mean								
	exgreen-mean								
	value-mean								
	saturation-mean								
	hue-mean								
	class								
Test mode:	10-fold cross-validation								
=== Stratified cross-validation ===									
=== Summary ===									
Correctly Classified Instances	2196	95.0649 %							
Incorrectly Classified Instances	114	4.9351 %							
Kappa statistic	0.9424								
Mean absolute error	0.0186								
Root mean squared error	0.1108								
Relative absolute error	7.5874 %								
Root relative squared error	31.665 %								
Total Number of Instances	2310								
=== Detailed Accuracy By Class ===									
	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0,973	0,007	0,961	0,973	0,967	0,961	0,996	0,978	brickface
	1,000	0,000	1,000	1,000	1,000	1,000	1,000	1,000	sky
	0,921	0,013	0,924	0,921	0,923	0,910	0,979	0,922	foliage
	0,909	0,014	0,917	0,909	0,913	0,899	0,983	0,952	cement
	0,894	0,023	0,865	0,894	0,879	0,859	0,970	0,870	window
	0,979	0,002	0,991	0,979	0,985	0,982	0,998	0,992	path
	0,979	0,000	1,000	0,979	0,989	0,988	0,994	0,989	grass
Weighted Avg.	0,951	0,008	0,951	0,951	0,951	0,943	0,988	0,957	
=== Confusion Matrix ===									

```

      a   b   c   d   e   f   g   <-- classified as
321    0   0   3   6   0   0 |   a = brickface
    0 330   0   0   0   0   0 |   b = sky
      2   0 304   4  20   0   0 |   c = foliage
      5   0   4 300  18   3   0 |   d = cement
      5   0  18  12 295   0   0 |   e = window
      0   0   0   7   0 323   0 |   f = path
      1   0   3   1   2   0 323 |   g = grass

```

<i>Key Fold</i> <i>Measures</i>	1	2	3	4	5	6	7	8	9	10
Number correct	220	218	216	219	217	218	220	225	220	223
Number incorrect	11	13	15	12	14	13	11	6	11	8
Number unclassified	0	0	0	0	0	0	0	0	0	0
Percent correct	95.238095	94.372294	93.506494	94.805195	93.939394	94.372294	95.238095	97.402597	95.238095	96.536797
Percent incorrect	4.761905	5.627706	6.493506	5.194805	6.060606	5.627706	4.761905	2.597403	4.761905	3.463203
Percent unclassified	0	0	0	0	0	0	0	0	0	0
True positive rate	0.939394	1	1	1	0.939394	0.939394	0.969697	0.939394	1	1
Num true positives	31	33	33	33	31	31	32	31	33	33
False positive rate	0.005051	0	0	0.005051	0.005051	0.015152	0	0.005051	0.015152	0.015152
Num false positives	1	0	0	1	1	3	0	1	3	3
True negative rate	0.994949	1	1	0.994949	0.994949	0.984848	1	0.994949	0.984848	0.984848
Num true negatives	197	198	198	197	197	195	198	197	195	195
False negative rate	0.060606	0	0	0	0.060606	0.060606	0.030303	0.060606	0	0
Num false negatives	2	0	0	0	2	2	1	2	0	0
Precision	0.96875	1	1	0.970588	0.96875	0.911765	1	0.96875	0.916667	0.916667
Recall	0.939394	1	1	1	0.939394	0.939394	0.969697	0.939394	1	1
F-measure	0.953846	1	1	0.985075	0.953846	0.925373	0.984615	0.953846	0.956522	0.956522

Tabella 5.3: Risultati della 10-fold CV per REPTree

Esecuzione JRip

=== Run information ===

```

Scheme:      weka.classifiers.rules.JRip -F 3 -N 2.0 -O 2 -S 1
Relation:    segment
Instances:    2310
Attributes:   20
              region-centroid-col
              region-centroid-row
              region-pixel-count
              short-line-density-5
              short-line-density-2
              vedge-mean
              vegde-sd
              hedge-mean
              hedge-sd
              intensity-mean
              rawred-mean
              rawblue-mean
              rawgreen-mean
              exred-mean
              exblue-mean

```

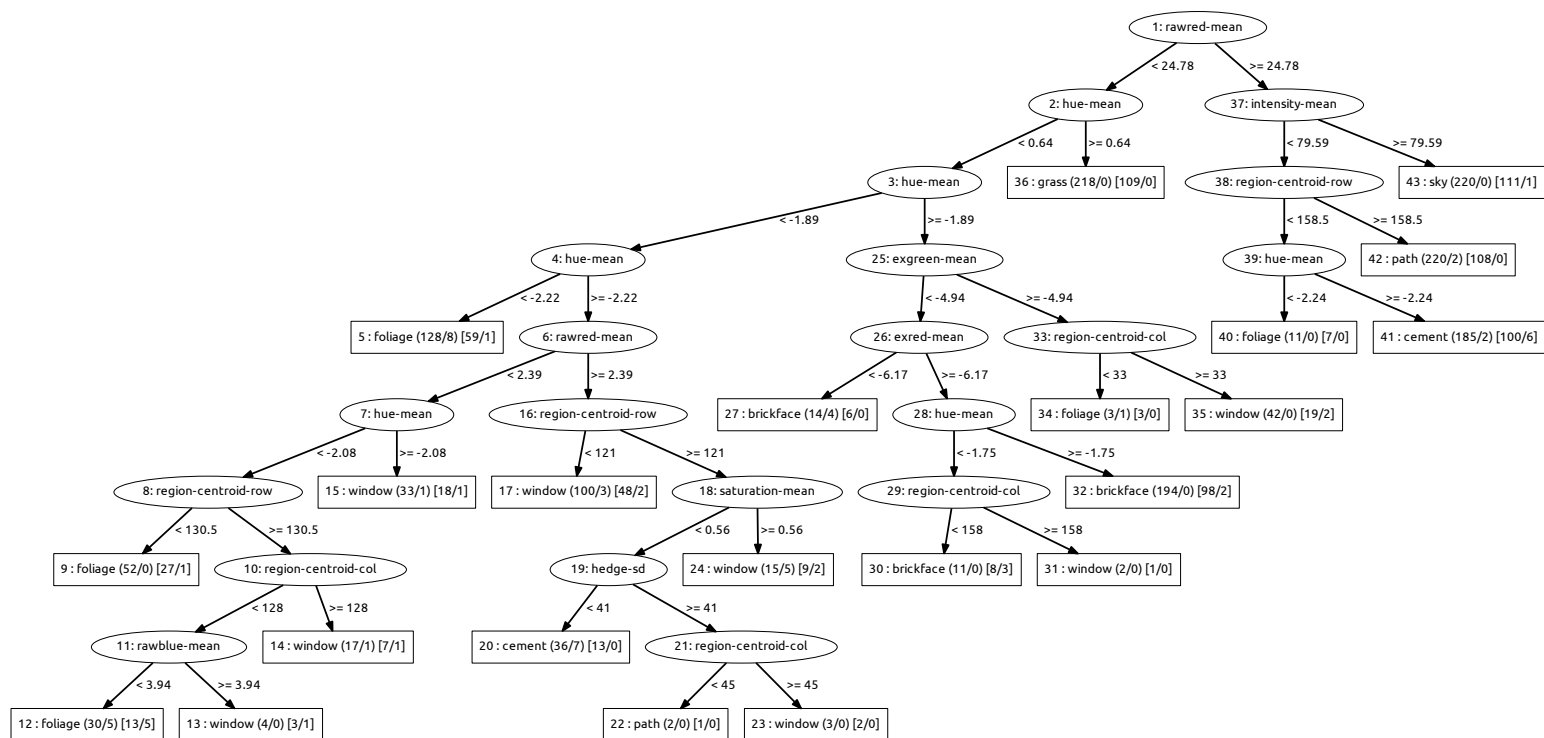



Figura 5.2: Modello di REPTree

```

exgreen-mean
value-mean
saturation-mean
hue-mean
class
Test mode: 10-fold cross-validation

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      2204           95.4113 %
Incorrectly Classified Instances    106           4.5887 %
Kappa statistic                    0.9465
Mean absolute error                 0.0172
Root mean squared error             0.1115
Relative absolute error              7.0261 %
Root relative squared error          31.8519 %
Total Number of Instances          2310

=== Detailed Accuracy By Class ===

TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
0,982    0,005    0,970     0,982    0,976     0,972    0,991     0,958     brickface
0,997    0,000    1,000     0,997    0,998     0,998    0,998     0,997     sky

```

	0,927	0,018	0,897	0,927	0,912	0,897	0,972	0,899	foliage
	0,930	0,012	0,930	0,930	0,930	0,919	0,977	0,932	cement
	0,864	0,014	0,913	0,864	0,888	0,870	0,965	0,874	window
	0,988	0,005	0,970	0,988	0,979	0,975	0,996	0,986	path
	0,991	0,001	0,997	0,991	0,994	0,993	0,999	0,995	grass
Weighted Avg.	0,954	0,008	0,954	0,954	0,954	0,946	0,986	0,949	
=== Confusion Matrix ===									
	a	b	c	d	e	f	g	<-- classified as	
324	0	1	3	2	0	0	0	a = brickface	
0	329	0	1	0	0	0	0	b = sky	
2	0	306	6	14	2	0	0	c = foliage	
3	0	6	307	10	3	1	1	d = cement	
5	0	24	11	285	5	0	0	e = window	
0	0	3	1	0	326	0	0	f = path	
0	0	1	1	1	0	327	1	g = grass	

Key Fold Measures	1	2	3	4	5	6	7	8	9	10
Number correct	222	216	223	219	218	221	220	221	221	223
Number incorrect	9	15	8	12	13	10	11	10	10	8
Number unclassified	0	0	0	0	0	0	0	0	0	0
Percent correct	96.103896	93.506494	96.536797	94.805195	94.372294	95.670996	95.238095	95.670996	95.670996	96.536797
Percent incorrect	3.896104	6.493506	3.463203	5.194805	5.627706	4.329004	4.761905	4.329004	4.329004	3.463203
Percent unclassified	0	0	0	0	0	0	0	0	0	0
True positive rate	0.969697	1	1	0.969697	0.969697	0.969697	0.969697	1	1	0.969697
Num true positives	32	33	33	32	32	32	32	33	33	32
False positive rate	0.005051	0.005051	0.005051	0	0.010101	0	0.005051	0.010101	0.005051	0.005051
Num false positives	1	1	1	0	2	0	1	2	1	1
True negative rate	0.994949	0.994949	0.994949	1	0.989899	1	0.994949	0.989899	0.994949	0.994949
Num true negatives	197	197	197	198	196	198	197	196	197	197
False negative rate	0.030303	0	0	0.030303	0.030303	0.030303	0.030303	0	0	0.030303
Num false negatives	1	0	0	1	1	1	1	0	0	1
Precision	0.969697	0.970588	0.970588	1	0.941176	1	0.969697	0.942857	0.970588	0.969697
Recall	0.969697	1	1	0.969697	0.969697	0.969697	0.969697	1	1	0.969697
F-measure	0.969697	0.985075	0.985075	0.984615	0.955224	0.984615	0.969697	0.970588	0.985075	0.969697

Tabella 5.4: Risultati della 10-fold CV per JRip

Regole:

1. (intensity-mean \geq 26.1111) **AND** (hue-mean \geq -2.17447) **AND** (region-centroid-row \leq 159) **AND** (intensity-mean \leq 72.8889) **AND** (rawgreen-mean \geq 22.3333) \Rightarrow class=cement (281.0/0.0)
2. (vedge-mean \geq 1.72222) **AND** (region-centroid-row \leq 160) **AND** (region-centroid-row \geq 146) **AND** (hedge-sd \leq 1.86667) **AND** (saturation-mean \leq 0.541667) \Rightarrow class=cement (20.0/1.0)
3. (region-centroid-row \geq 123) **AND** (hue-mean \leq -2.10408) **AND** (hue-mean \geq -2.17535) **AND** (rawred-mean \geq 8) **AND** (region-centroid-row \leq 156) \Rightarrow class=cement (19.0/1.0)
4. (intensity-mean \geq 86.2963) \Rightarrow class=sky (330.0/0.0)
5. (hue-mean \geq 1.28706) \Rightarrow class=grass (327.0/0.0)

6. (hedge-mean ≤ 0.777777) **AND** (region-centroid-col ≥ 128) **AND** (saturation-mean ≤ 0.533928) **AND** (exred-mean ≤ 0.111111) \Rightarrow class=window (91.0/0.0)
7. (rawred-mean ≤ 18.2222) **AND** (region-centroid-col ≥ 152) **AND** (rawblue-mean ≥ 9.55556) **AND** (hue-mean ≥ -2.20829) \Rightarrow class=window (82.0/0.0)
8. (intensity-mean ≤ 3.7037) **AND** (hue-mean ≥ -2.08783) **AND** (region-centroid-col ≥ 34) \Rightarrow class=window (62.0/1.0)
9. (hue-mean ≤ -2.0793) **AND** (hue-mean ≥ -2.21646) **AND** (rawred-mean ≥ 0.666667) **AND** (rawred-mean ≤ 25.6667) **AND** (exgreen-mean ≤ -6.22222) **AND** (exblue-mean ≤ 33.6667) \Rightarrow class=window (51.0/2.0)
10. (vedge-mean ≤ 0.277778) **AND** (region-centroid-row ≥ 131) **AND** (region-centroid-col ≥ 125) \Rightarrow class=window (8.0/1.0)
11. (exgreen-mean ≥ -6.11111) **AND** (region-centroid-row ≥ 133) **AND** (hue-mean ≥ -2.1753) **AND** (exgreen-mean ≤ -3.11111) **AND** (region-centroid-col ≥ 38) \Rightarrow class=window (18.0/3.0)
12. (intensity-mean ≤ 2.96296) **AND** (region-centroid-row ≥ 133) **AND** (rawred-mean ≥ 0.888889) \Rightarrow class=window (5.0/0.0)
13. (exgreen-mean ≥ -6.33333) **AND** (region-centroid-row ≤ 133) \Rightarrow class=foliage (233.0/5.0)
14. (hue-mean ≤ -2.0944) **AND** (region-centroid-row ≤ 145) \Rightarrow class=foliage (98.0/11.0)
15. (rawred-mean ≤ 18.4444) **AND** (exred-mean ≤ -6) \Rightarrow class=foliage (13.0/4.0)
16. (region-centroid-row ≤ 149) \Rightarrow class=brickface (334.0/7.0)
17. [Empty Rule] \Rightarrow class=path (338.0/10.0)

5.3 Risultati su Vehicle Silhouettes

L'esecuzione ha coinvolto 761 istanze di training e 85 istanze di testing.

Esecuzione REPTree

=== Run information ===

Scheme:weka.classifiers.trees.REPTree -M 2 -V 0.001 -N 3 -S 1 -L -1 -I 0.0

Relation:vehicle

Instances:846

Attributes:19

COMPACTNESS

CIRCULARITY

DISTANCE CIRCULARITY

RADIUS RATIO

PR.AXIS ASPECT RATIO

MAX.LENGTH ASPECT RATIO

SCATTER RATIO

ELONGATEDNESS

PR.AXIS RECTANGULARITY

MAX.LENGTH RECTANGULARITY

SCALED VARIANCE_MAJOR

SCALED VARIANCE_MINOR

SCALED RADIUS OF GYRATION

SKEWNESS ABOUT_MAJOR

SKEWNESS ABOUT_MINOR

KURTOSIS ABOUT_MAJOR

KURTOSIS ABOUT_MINOR

HOLLOWS RATIO

Class

Test mode:10-fold cross-validation

=== Stratified cross-validation ===

=== Summary ===

Correctly Classified Instances

612

72.3404 %

Incorrectly Classified Instances

234

27.6596 %

Kappa statistic

0.6313

Mean absolute error

0.1617

Root mean squared error

0.3109

Relative absolute error

43.1254 %

Root relative squared error

71.8227 %

Total Number of Instances

846

=== Detailed Accuracy By Class ===

TP Rate

0,575

FP Rate

0,137

Precision

0,584

Recall

0,575

F-Measure

0,580

MCC

0,440

ROC Area

0,842

PRC Area

0,586

Class

opel

TP Rate

0,475

FP Rate

0,129

Precision

0,560

Recall

0,475

F-Measure

0,514

MCC

0,366

ROC Area

0,795

PRC Area

0,561

Class

saab

TP Rate

0,945

FP Rate

0,040

Precision

0,892

Recall

0,945

F-Measure

0,918

MCC

0,889

ROC Area

0,968

PRC Area

0,895

Class

bus

TP Rate

0,910

FP Rate

0,063

Precision

0,815

Recall

0,910

F-Measure

0,860

MCC

0,816

ROC Area

0,972

PRC Area

0,879

Class

van

Weighted Avg.

0,723

FP Rate

0,093

Precision

0,711

Recall

0,723

F-Measure

0,716

MCC

0,625

ROC Area

0,893

PRC Area

0,728

Class

=== Confusion Matrix ===

a

b

c

d

<-- classified as

122

68

8

14

|

a = opel

81

103

13

20

|

b = saab

1	4	206	7		c = bus
5	9	4	181		d = van

<i>Measures</i> \ <i>Key Fold</i>	1	2	3	4	5	6	7	8	9	10
Number correct	55	64	66	62	58	64	57	58	63	65
Number incorrect	30	21	19	23	27	21	27	26	21	19
Number unclassified	0	0	0	0	0	0	0	0	0	0
Percent correct	64.705882	75.294118	77.647059	72.941176	68.235294	75.294118	67.857143	69.047619	75	77.380952
Percent incorrect	35.294118	24.705882	22.352941	27.058824	31.764706	24.705882	32.142857	30.952381	25	22.619048
Percent unclassified	0	0	0	0	0	0	0	0	0	0
True positive rate	0.380952	0.619048	0.714286	0.761905	0.619048	0.428571	0.47619	0.454545	0.681818	0.619048
Num true positives	8	13	15	16	13	9	10	10	15	13
False positive rate	0.15625	0.140625	0.109375	0.21875	0.171875	0.046875	0.15873	0.145161	0.129032	0.095238
Num false positives	10	9	7	14	11	3	10	9	8	6
True negative rate	0.84375	0.859375	0.890625	0.78125	0.828125	0.953125	0.84127	0.854839	0.870968	0.904762
Num true negatives	54	55	57	50	53	61	53	53	54	57
False negative rate	0.619048	0.380952	0.285714	0.238095	0.380952	0.571429	0.52381	0.545455	0.318182	0.380952
Num false negatives	13	8	6	5	8	12	11	12	7	8
Precision	0.444444	0.590909	0.681818	0.533333	0.541667	0.75	0.5	0.526316	0.652174	0.684211
Recall	0.380952	0.619048	0.714286	0.761905	0.619048	0.428571	0.47619	0.454545	0.681818	0.619048
F-measure	0.410256	0.604651	0.697674	0.627451	0.577778	0.545455	0.487805	0.487805	0.666667	0.65

Tabella 5.5: Risultati della 10-fold CV per REPTree

Esecuzione JRip	
<pre> === Run information === Scheme: weka.classifiers.rules.JRip -F 3 -N 2.0 -O 2 -S 1 Relation: vehicle Instances: 846 Attributes: 19 COMPACTNESS CIRCULARITY DISTANCE CIRCULARITY RADIUS RATIO PR.AXIS ASPECT RATIO MAX.LENGTH ASPECT RATIO SCATTER RATIO ELONGATEDNESS PR.AXIS RECTANGULARITY MAX.LENGTH RECTANGULARITY SCALED VARIANCE_MAJOR SCALED VARIANCE_MINOR SCALED RADIUS OF GYRATION SKEWNESS ABOUT_MAJOR SKEWNESS ABOUT_MINOR KURTOSIS ABOUT_MAJOR KURTOSIS ABOUT_MINOR HOLLOWS RATIO Class Test mode: 10-fold cross-validation === Stratified cross-validation === </pre>	

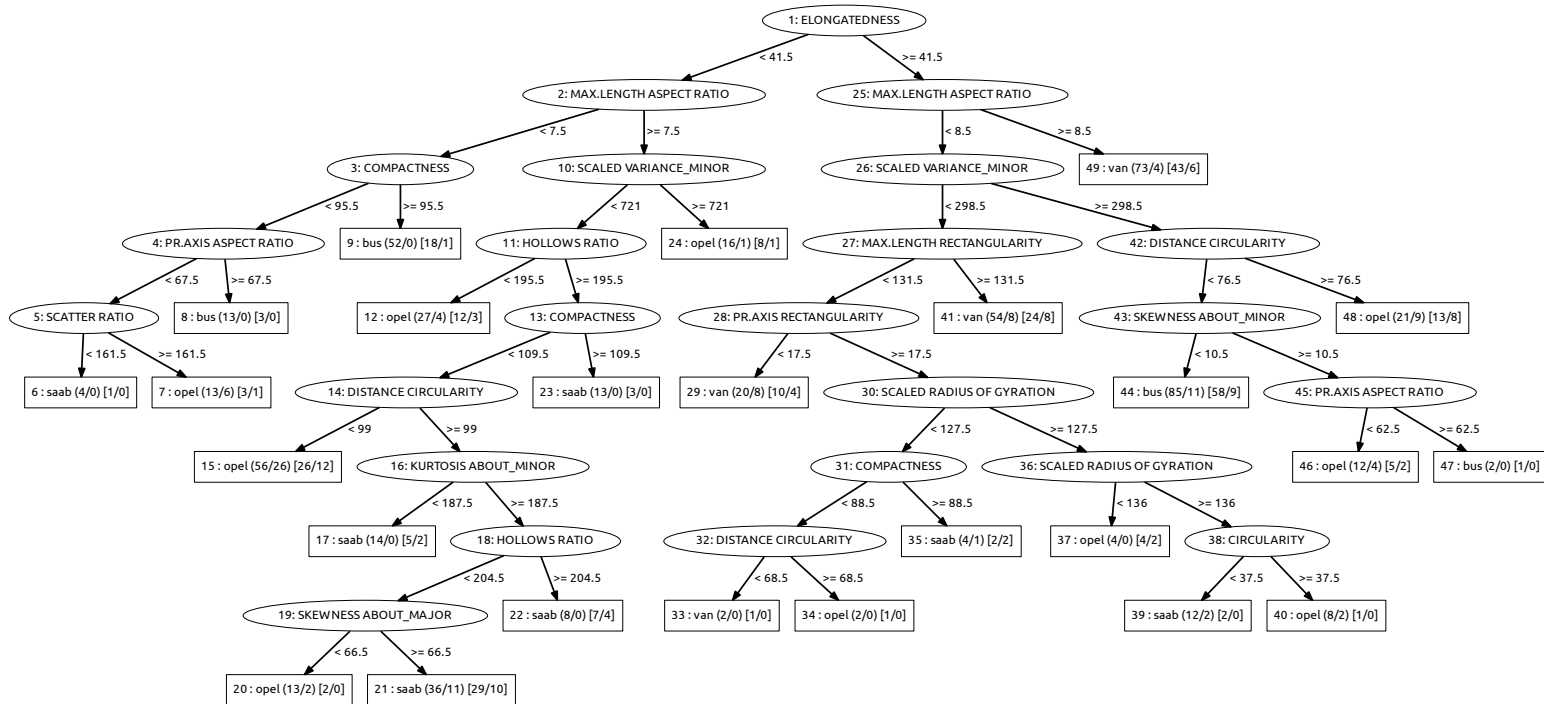


Figura 5.3: Modello di REPTree

=== Summary ===

Correctly Classified Instances	584	69.0307 %
Incorrectly Classified Instances	262	30.9693 %
Kappa statistic	0.5868	
Mean absolute error	0.1914	
Root mean squared error	0.3323	
Relative absolute error	51.0598 %	
Root relative squared error	76.7524 %	
Total Number of Instances	846	

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	MCC	ROC Area	PRC Area	Class
	0,481	0,126	0,560	0,481	0,518	0,374	0,785	0,545	opel
	0,484	0,146	0,533	0,484	0,507	0,349	0,793	0,501	saab
	0,940	0,099	0,768	0,940	0,845	0,792	0,940	0,812	bus
	0,864	0,043	0,860	0,864	0,862	0,820	0,927	0,861	van
Weighted Avg.	0,690	0,105	0,677	0,690	0,680	0,580	0,860	0,677	

=== Confusion Matrix ===

a	b	c	d	<-- classified as
102	71	27	12	a = opel
74	105	27	11	b = saab
2	6	205	5	c = bus

4 15 8 172 | d = van

Key Fold Measures	1	2	3	4	5	6	7	8	9	10
Number correct	51	66	54	57	58	59	54	60	58	67
Number incorrect	34	19	31	28	27	26	30	24	26	17
Number unclassified	0	0	0	0	0	0	0	0	0	0
Percent correct	60	77.647059	63.529412	67.058824	68.235294	69.411765	64.285714	71.428571	69.047619	79.761905
Percent incorrect	40	22.352941	36.470588	32.941176	31.764706	30.588235	35.714286	28.571429	30.952381	20.238095
Percent unclassified	0	0	0	0	0	0	0	0	0	0
True positive rate	0.095238	0.666667	0.428571	0.285714	0.571429	0.666667	0.52381	0.545455	0.409091	0.619048
Num true positives	2	14	9	6	12	14	11	12	9	13
False positive rate	0.046875	0.09375	0.15625	0.125	0.140625	0.1875	0.190476	0.096774	0.145161	0.079365
Num false positives	3	6	10	8	9	12	12	6	9	5
True negative rate	0.953125	0.90625	0.84375	0.875	0.859375	0.8125	0.809524	0.903226	0.854839	0.920635
Num true negatives	61	58	54	56	55	52	51	56	53	58
False negative rate	0.904762	0.333333	0.571429	0.714286	0.428571	0.333333	0.47619	0.454545	0.590909	0.380952
Num false negatives	19	7	12	15	9	7	10	10	13	8
Precision	0.4	0.7	0.473684	0.428571	0.571429	0.538462	0.478261	0.666667	0.5	0.722222
Recall	0.095238	0.666667	0.428571	0.285714	0.571429	0.666667	0.52381	0.545455	0.409091	0.619048
F-measure	0.153846	0.682927	0.45	0.342857	0.571429	0.595745	0.5	0.6	0.45	0.666667

Tabella 5.6: Risultati della 10-fold CV per JRip

Regole:

- (ELONGATEDNESS ≥ 43) **AND** (MAX.LENGTH ASPECT RATIO ≥ 9) **AND** (DISTANCE CIRCULARITY ≥ 73) \Rightarrow Class=van (86.0/0.0)
- (SCALED VARIANCE.MINOR ≤ 309) **AND** (MAX.LENGTH RECTANGULARITY ≥ 132) **AND** (DISTANCE CIRCULARITY ≤ 64) **AND** (SCALED RADIUS OF GYRATION ≤ 157) \Rightarrow Class=van (23.0/0.0)
- (PR.AXIS RECTANGULARITY ≤ 18) **AND** (MAX.LENGTH RECTANGULARITY ≥ 128) **AND** (SCALED RADIUS OF GYRATION ≤ 140) \Rightarrow Class=van (42.0/6.0)
- (SCALED VARIANCE.MINOR ≤ 309) **AND** (MAX.LENGTH RECTANGULARITY ≥ 142) \Rightarrow Class=van (33.0/5.0)
- (ELONGATEDNESS ≥ 53) **AND** (SCALED RADIUS OF GYRATION ≥ 137) \Rightarrow Class=van (15.0/5.0)
- (SCALED VARIANCE.MAJOR ≤ 177) **AND** (MAX.LENGTH ASPECT RATIO ≥ 10) \Rightarrow Class=van (8.0/1.0)
- (MAX.LENGTH ASPECT RATIO ≥ 8) **AND** (MAX.LENGTH RECTANGULARITY ≥ 173) \Rightarrow Class=opel (45.0/8.0)
- (MAX.LENGTH ASPECT RATIO ≥ 8) **AND** (COMPACTNESS ≤ 103) **AND** (ELONGATEDNESS ≤ 37) **AND** (HOLLOWS RATIO ≤ 195) \Rightarrow Class=opel (14.0/0.0)
- (MAX.LENGTH ASPECT RATIO ≥ 8) **AND** (HOLLOWS RATIO ≤ 198) **AND** (KURTOSIS ABOUT.MINOR ≥ 189) \Rightarrow Class=opel (42.0/17.0)
- (SKEWNESS ABOUT.MAJOR ≤ 67) **AND** (HOLLOWS RATIO ≤ 203) \Rightarrow Class=opel (66.0/30.0)

11. (SCALED RADIUS OF GYRATION ≤ 142) **AND** (HOLLOWS RATIO ≤ 194) **AND** (DISTANCE CIRCULARITY ≥ 57) \Rightarrow Class=opel (17.0/2.0)
12. (MAX.LENGTH ASPECT RATIO ≥ 9) **AND** (DISTANCE CIRCULARITY ≥ 100) **AND** (SCALED VARIANCE_MAJOR ≤ 231) \Rightarrow Class=saab (71.0/9.0)
13. (MAX.LENGTH ASPECT RATIO ≥ 9) **AND** (PR.AXIS ASPECT RATIO ≤ 61) \Rightarrow Class=saab (23.0/7.0)
14. (SCALED VARIANCE_MAJOR ≤ 165) **AND** (DISTANCE CIRCULARITY ≤ 66) \Rightarrow Class=saab (36.0/11.0)
15. (SKEWNESS ABOUT_MAJOR ≤ 72) **AND** (PR.AXIS ASPECT RATIO ≤ 65) **AND** (DISTANCE CIRCULARITY ≥ 81) **AND** (SKEWNESS ABOUT_MAJOR ≥ 66) \Rightarrow Class=saab (27.0/7.0)
16. (CIRCULARITY ≤ 40) **AND** (RADIUS RATIO ≤ 144) \Rightarrow Class=saab (16.0/6.0)
17. [*Empty Rule*] \Rightarrow Class=bus (282.0/69.0)

5.4 Risultati su Wisconsin Breast Cancer

L'esecuzione ha coinvolto 629 istanze di training e 70 istanze di testing.

```

Esecuzione REPTree

=== Run information ===

Scheme:weka.classifiers.trees.REPTree -M 2 -V 0.001 -N 3 -S 1 -L -1
Relation:      wisconsin-breast-cancer
Instances:     699
Attributes:    10
               Clump_Thickness
               Cell_Size_Uniformity
               Cell_Shape_Uniformity
               Marginal_Adhesion
               Single_Epi_Cell_Size
               Bare_Nuclei
               Bland_Chromatin
               Normal_Nucleoli
               Mitoses
               Class

Test mode:10-fold cross-validation

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      656                93.8484 %
Incorrectly Classified Instances    43                 6.1516 %
Kappa statistic                    0.8653
Mean absolute error                 0.083
Root mean squared error             0.2234
Relative absolute error             18.3662 %
Root relative squared error         47.0064 %
Total Number of Instances          699

=== Detailed Accuracy By Class ===

               TP Rate   FP Rate   Precision   Recall   F-Measure   ROC Area   Class
               0.941     0.066     0.964      0.941     0.952       0.964     benign
               0.934     0.059     0.893      0.934     0.913       0.964     malignant
Weighted Avg.   0.938     0.064     0.94       0.938     0.939       0.964

=== Confusion Matrix ===

   a   b  <-- classified as
431  27 |   a = benign
 16 225 |   b = malignant

```

--

<i>Key Fold</i> <i>Measures</i>	1	2	3	4	5	6	7	8	9	10
Number correct	69	63	67	62	64	69	66	65	66	65
Number incorrect	1	7	3	8	6	1	4	5	4	4
Number unclassified	0	0	0	0	0	0	0	0	0	0
Percent correct	98.571429	90	95.714286	88.571429	91.428571	98.571429	94.285714	92.857143	94.285714	94.202899
Percent incorrect	1.428571	10	4.285714	11.428571	8.571429	1.428571	5.714286	7.142857	5.714286	5.797101
Percent unclassified	0	0	0	0	0	0	0	0	0	0
True positive rate	0.978261	0.978261	0.956522	0.891304	0.869565	0.978261	0.934783	0.934783	0.955556	0.933333
Num true positives	45	45	44	41	40	45	43	43	43	42
False positive rate	0	0.25	0.041667	125	0	0	0.041667	0.083333	0.08	0.041667
Num false positives	0	6	1	3	0	0	1	2	2	1
True negative rate	1	0.75	0.958333	875	1	1	0.958333	0.916667	0.92	0.958333
Num true negatives	24	18	23	21	24	24	23	22	23	23
False negative rate	0.021739	0.021739	0.043478	0.108696	0.130435	0.021739	0.065217	0.065217	0.044444	0.066667
Num false negatives	1	1	2	5	6	1	3	3	2	3
Precision	1	0.882353	0.977778	0.931818	1	1	0.977273	0.955556	0.955556	0.976744
Recall	0.978261	0.978261	0.956522	0.891304	0.869565	0.978261	0.934783	0.934783	0.955556	0.933333
F-measure	0.989011	0.927835	0.967033	0.911111	0.930233	0.989011	0.955556	0.945055	0.955556	0.954545

Tabella 5.7: Risultati della 10-fold CV per REPTree

Esecuzione JRip		
<pre> === Run information === Scheme:weka.classifiers.rules.JRip -F 3 -N 2.0 -O 2 -S 1 Relation: wisconsin-breast-cancer Instances: 699 Attributes: 10 Clump_Thickness Cell_Size_Uniformity Cell_Shape_Uniformity Marginal_Adhesion Single_Epi_Cell_Size Bare_Nuclei Bland_Chromatin Normal_Nucleoli Mitoses Class Test mode:10-fold cross-validation === Stratified cross-validation === === Summary === Correctly Classified Instances 667 95.422 % Incorrectly Classified Instances 32 4.578 % </pre>		




Figura 5.4: Modello di REPTree

```

Kappa statistic                0.8999
Mean absolute error            0.0618
Root mean squared error       0.2022
Relative absolute error       13.676 %
Root relative squared error   42.5462 %
Total Number of Instances     699

```

=== Detailed Accuracy By Class ===

	TP Rate	FP Rate	Precision	Recall	F-Measure	ROC Area	Class
	0.952	0.041	0.978	0.952	0.965	0.973	benign
	0.959	0.048	0.913	0.959	0.935	0.973	malignant
Weighted Avg.	0.954	0.044	0.955	0.954	0.954	0.973	

=== Confusion Matrix ===

```

a   b   <-- classified as
436 22 |   a = benign

```

10 231 | b = malignant

<i>Key Fold</i> <i>Measures</i>	1	2	3	4	5	6	7	8	9	10
Number correct	69	64	68	66	64	69	67	68	67	65
Number incorrect	1	6	2	4	6	1	3	2	3	4
Number unclassified	0	0	0	0	0	0	0	0	0	0
Percent correct	98.571429	91.428571	97.142857	94.285714	91.428571	98.571429	95.714286	97.142857	95.714286	94.202899
Percent incorrect	1.428571	8.571429	2.857143	5.714286	8.571429	1.428571	4.285714	2.857143	4.285714	5.797101
Percent unclassified	0	0	0	0	0	0	0	0	0	0
True positive rate	0.978261	0.956522	0.956522	0.913043	0.891304	1	0.934783	0.978261	0.977778	0.933333
Num true positives	45	44	44	42	41	46	43	45	44	42
False positive rate	0	0.166667	0	0	0.041667	0.041667	0	0.041667	0.08	0.041667
Num false positives	0	4	0	0	1	1	0	1	2	1
True negative rate	1	0.833333	1	1	0.958333	0.958333	1	0.958333	0.92	0.958333
Num true negatives	24	20	24	24	23	23	24	23	23	23
False negative rate	0.021739	0.043478	0.043478	0.086957	0.108696	0	0.065217	0.021739	0.022222	0.066667
Num false negatives	1	2	2	4	5	0	3	1	1	3
Precision	1	0.916667	1	1	0.97619	0.978723	1	0.978261	0.956522	0.976744
Recall	0.978261	0.956522	0.956522	0.913043	0.891304	1	0.934783	0.978261	0.977778	0.933333
F-measure	0.989011	0.93617	0.977778	0.954545	0.931818	0.989247	0.966292	0.978261	0.967033	0.954545

Tabella 5.8: Risultati della 10-fold CV per JRip

Regole:

1. (Cell.Size.Uniformity >= 3) **AND** (Cell.Size.Uniformity >= 5) \Rightarrow Class=malignant (178.0/5.0)
2. (Bare.Nuclei >= 4) **AND** (Bare.Nuclei >= 7) \Rightarrow Class=malignant (48.0/4.0)
3. (Normal.Nucleoli >= 3) **AND** (Clump.Thickness >= 6) \Rightarrow Class=malignant (13.0/1.0)
4. (Bare.Nuclei >= 3) **AND** (Clump.Thickness >= 5) \Rightarrow Class=malignant (11.0/3.0)
5. (Marginal.Adhesion >= 8) \Rightarrow Class=malignant (2.0/0.0)
6. [Empty Rule] \Rightarrow Class=benign (447.0/2.0)

Bibliografia

- [1] C. Brunk and M. J. Pazzani. An investigation of noise-tolerant relational concept learning algorithms, 1991.
- [2] W. W. Cohen. Efficient pruning methods for separate-and-conquer rule learning systems. In *In Proceedings of the 13th International Joint Conference on Artificial Intelligence*, pages 988–994. Morgan Kaufmann, 1993.
- [3] W. W. Cohen. Fast effective rule induction. In *In Proceedings of the Twelfth International Conference on Machine Learning*, pages 115–123. Morgan Kaufmann, 1995.
- [4] F. Esposito, D. Malerba, and G. Semeraro. A comparative analysis of methods for pruning decision trees. *IEEE Trans. Pattern Anal. Mach. Intell.*, 19(5):476–491, May 1997. ISSN 0162-8828.
- [5] J. Fürnkranz and G. Widmer. Incremental reduced error pruning, 1994.
- [6] G. Pagallo, D. Haussler, and P. Rosenbloom. © 1990 kluwer academic publishers. manufactured in the netherlands. boolean feature discovery in empirical learning, 1990.
- [7] J. Quinlan. Learning logical definitions from relations. *Machine Learning*, 5(3): 239–266, 1990. ISSN 1573-0565.
- [8] J. R. Quinlan. Simplifying decision trees. *Int. J. Man-Mach. Stud.*, 27(3):221–234, Sept. 1987. ISSN 0020-7373.
- [9] J. R. Quinlan. *C4.5: Programs for Machine Learning*. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 1993. ISBN 1-55860-238-0.
- [10] J. R. Quinlan. MDL and categorical theories (continued). In *In Machine Learning: Proceedings of the Twelfth International Conference, Lake Tahoe*, pages 464–470. Morgan Kaufmann, 1995.
- [11] J. R. Quinlan and R. L. Rivest. Inferring decision trees using the minimum description length principle. *Inf. Comput.*, 80(3):227–248, Mar. 1989. ISSN 0890-5401.
- [12] S. J. Russell and P. Norvig. *Artificial Intelligence: A Modern Approach*. Pearson Education, 2 edition, 2003. ISBN 0137903952.

- [13] C. E. Shannon. A Mathematical Theory of Communication. *The Bell System Technical Journal*, 27(3):379–423, 1948.
- [14] S. M. Weiss and N. Indurkha. Reduced complexity rule induction. In *In Proceedings of the 12th International Joint Conference on Artificial Intelligence (IJCAI-91)*, pages 678–684. Morgan Kaufmann, 1991.
- [15] I. H. Witten, E. Frank, and M. A. Hall. Decision trees. In *Data Mining: Practical Machine Learning Tools and Techniques*, chapter 6.2, page 206. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 3rd edition, 2011. ISBN 0123748569, 9780123748560.
- [16] I. H. Witten, E. Frank, and M. A. Hall. Decision trees. In *Data Mining: Practical Machine Learning Tools and Techniques*, chapter 11.4, page 456. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 3rd edition, 2011. ISBN 0123748569, 9780123748560.
- [17] I. H. Witten, E. Frank, and M. A. Hall. Decision trees. In *Data Mining: Practical Machine Learning Tools and Techniques*, chapter 6.11, page 303. Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 3rd edition, 2011. ISBN 0123748569, 9780123748560.